



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное
образовательное учреждение высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ

КАФЕДРА ПРОГРАММНОЕ ОБЕСПЕЧЕНИЕ ЭВМ И ИНФОРМАЦИОННЫЕ ТЕХНОЛОГИИ

ОТЧЕТ ПО ПРОИЗВОДСТВЕННОЙ ПРАКТИКЕ

Студент _____ Фролов Евгений _____
фамилия, имя, отчество

Группа ИУ7-85Б

Тип практики _____ Преддипломная практика

Название предприятия _____ НУК ИУ МГТУ им. Н.Э. Баумана

Студент _____ Фролов Е. _____
подпись, дата *фамилия, и.о.*

Руководитель практики _____ Кострицкий А. С. _____
подпись, дата *фамилия, и.о.*

Оценка _____

2026 г.

(Подпись, дата)

Е. Фролов
(И.О.Фамилия)

Содержание

ВВЕДЕНИЕ	6
1 Формализованная постановка задачи	8
2 Тестирование программного обеспечения	12
2.1 Функциональное тестирование	12
2.1.1 Алгоритм тестирования	13
2.1.2 Классы эквивалентности	14
2.1.3 Результаты функционального тестирования	16
2.2 Модульное тестирование	17
2.3 Тестирование графического интерфейса	17
3 Исследование разработанного ПО	18
3.1 Постановка и условия исследования	18
3.2 Результаты исследования	20
3.3 Выводы	24
ЗАКЛЮЧЕНИЕ	25

ВВЕДЕНИЕ

Актуальность темы исследования обусловлена современными тенденциями в банковском секторе, где эффективность принятия кредитных решений зависит от точности и скорости скоринговых методов. Скоринг является ключевым инструментом для разделения потенциальных заемщиков на «хороших» – тех, кто с высокой вероятностью вернет кредит, и «плохих» – тех, кто, скорее всего, не вернет кредит. Эти термины общеприняты в данной области и отражают степень кредитоспособности клиентов.

В скоринге используются косвенные признаки, поскольку прямые признаки надежности заемщика отсутствуют. Оцениваются сведения о заемщике, включая уровень дохода, наличие действующих кредитных обязательств, возраст, трудовой стаж и другие значимые характеристики. На их основе строится комплексный критерий для принятия решения о выдаче кредита.

В последние годы динамика кредитования физических лиц в России характеризуется существенными изменениями. По данным Frank RG, в 2025 году объем выданных кредитов физическим лицам составил около 9,89 трлн рублей, что на 25,6% ниже уровня 2024 года. Это стало минимальным значением за последние шесть лет. Одновременно наблюдается снижение спроса на кредитные продукты на фоне ужесточения денежно-кредитной политики. При этом сохраняется значительный уровень просроченной задолженности, что повышает кредитные риски банковской системы и усиливает требования к точности скоринговых моделей.

Распространение современных финансовых технологий привело к трансформации рынка финансовых услуг и формированию новых моделей финансирования, таких как краудфандинг, краудинвестинг, P2P-кредитование и другие. Для сохранения конкурентоспособности банки вынуждены совершенствоваться, повышая скорость обработки заявок и оценки кредитоспособности заемщиков.

Актуальность работы состоит в необходимости повышения точности и эффективности оценки кредитоспособности заемщиков в условиях роста объемов кредитования и увеличения рисков. Современные банковские системы требуют автоматизированных решений, способных обрабатывать большие объемы данных и учитывать различные факторы, влияющие на вероятность дефолта.

Традиционные методы оценки кредитного риска не всегда обеспечивают достаточную точность, что приводит к финансовым потерям. В связи с этим возрастает интерес к методам машинного обучения. Их применение позволяет повысить качество прогнозирования и адаптироваться к изменяющимся условиям.

Цель работы заключается в разработке модели оценки кредитоспособности заемщика на основе методов машинного обучения, обеспечивающей высокую точность прогнозирования кредитного риска.

Для достижения поставленной цели требуется решить следующие задачи:

- изучить существующие методы оценки кредитоспособности заемщиков;
- провести анализ методов машинного обучения, применяемых в скоринге;
- разработать модель оценки кредитного риска на основе градиентного бустинга;
- реализовать программную модель и провести ее обучение;
- оценить качество разработанной модели и сравнить с альтернативными методами.

1 Формализованная постановка задачи

Во время выполнения выпускной квалификационной работы была формализована задача оценки кредитоспособности физических лиц в банковских системах с использованием алгоритма градиентного бустинга деревьев решений.

Разрабатываемое программное обеспечение предназначено для обработки входных данных заемщика, формирования признакового описания, применения обученной модели машинного обучения и получения результата скоринговой оценки.

Общая структура системы оценки кредитоспособности заемщика представлена на рисунке 1.1.




Рисунок 1.1 – IDEF0-диаграмма верхнего уровня процесса оценки кредитоспособности

На диаграмме представлены входные данные системы, управляющие воздействия, используемые механизмы и результаты работы программного комплекса.

Декомпозиция процесса оценки кредитоспособности представлена на рисунке 1.2.




Рисунок 1.2 – Декомпозиция процесса оценки кредитоспособности заемщика

Пусть задано множество заемщиков:

$$D = \{(x_i, y_i)\}_{i=1}^n, \tag{1.1}$$

- где $x_i \in \mathbb{R}^d$ — вектор признаков заемщика;
- y_i — целевая переменная;
- n — количество объектов в выборке;
- d — количество признаков.

Вектор признаков заемщика имеет следующий вид:

$$x_i = (x_{i1}, x_{i2}, \dots, x_{id}), \tag{1.2}$$

где x_{ij} — значение j -го признака для i -го заемщика.

Признаковое описание заемщика формируется на основе совокупности социально-демографических, финансовых и поведенческих параметров. К ним относятся доход заемщика, сумма запрашиваемого кредита, размер ежемесяч-

ного платежа, возраст, трудовой стаж, сведения о кредитной истории, наличие просроченных платежей и информация о ранее поданных кредитных заявках.

Целевая переменная определяется следующим образом:

$$y_i = \begin{cases} 0, & \text{если заемщик не допустил дефолт;} \\ 1, & \text{если заемщик допустил дефолт.} \end{cases} \quad (1.3)$$

Задача модели заключается в построении функции:

$$f : X \rightarrow [0; 1], \quad (1.4)$$

где X — пространство признаков заемщиков.

Функция $f(x_i)$ возвращает вероятность дефолта заемщика:

$$p_i = f(x_i) = P(y_i = 1 \mid x_i), \quad (1.5)$$

где p_i — вероятность наступления дефолта для i -го заемщика.

На основе полученной вероятности дефолта формируется скоринговый балл:

$$S_i = (1 - p_i) \cdot 1000, \quad (1.6)$$

где S_i — скоринговый балл заемщика.

Для принятия решения используется пороговое значение вероятности дефолта:

$$t = 0.5, \quad (1.7)$$

где t — порог классификации.

Решение о принадлежности заемщика к определенному классу определяется следующим образом:

$$\hat{y}_i = \begin{cases} 0, & \text{если } p_i < t; \\ 1, & \text{если } p_i \geq t. \end{cases} \quad (1.8)$$

где $\hat{y}_i$ — результат классификации заемщика.

Значение $\hat{y}_i = 0$ соответствует заемщику с низким уровнем риска, а значение $\hat{y}_i = 1$ соответствует заемщику с высоким уровнем риска дефолта.

Таким образом, задача оценки кредитоспособности физических лиц сводится к задаче бинарной классификации, в которой на основе признакового описания заемщика необходимо определить вероятность наступления дефолта и сформировать итоговое скоринговое решение.

2 Тестирование программного обеспечения

В данном разделе рассматривается тестирование программного обеспечения, разработанного для оценки кредитоспособности физических лиц с использованием алгоритма градиентного бустинга деревьев решений.

Целью тестирования являлась проверка корректности работы основных компонентов программного комплекса: ввода данных заемщика, формирования входного JSON-файла, запуска Python-модуля предсказания, получения результата скоринга и отображения результата в пользовательском интерфейсе.

Тестирование выполнялось на синтетических наборах данных, подготовленных для проверки различных сценариев работы приложения. Дополнительно проверялась возможность загрузки данных заемщика из JSON-файла.

2.1 Функциональное тестирование

Функциональное тестирование проводилось для проверки соответствия разработанного программного обеспечения заданным требованиям. В ходе тестирования проверялась работа основных функций системы, связанных с вводом данных заемщика, обработкой информации, запуском модуля предсказания и отображением результата кредитного скоринга.

При проведении функционального тестирования были рассмотрены следующие варианты работы программы:

- ручной ввод данных заемщика через формы приложения;
- формирование JSON-структуры на основе введенных данных;
- загрузка данных заемщика из JSON-файла;
- запуск Python-модуля предсказания из C#-приложения;
- получение результата работы модели в формате JSON;
- отображение вероятности дефолта, скорингового балла и уровня риска;
- отображение факторов риска и рекомендаций;

- обработка ошибок при отсутствии файла или некорректных входных данных.

Разработанное приложение принимает входные данные о заемщике, передает их в модуль предсказания, реализованный на языке Python, и получает результат оценки кредитоспособности. Взаимодействие между приложением и Python-модулем выполняется посредством запуска Python-скрипта через класс `ProcessStartInfo` с последующим чтением результата из стандартного потока вывода.

2.1.1 Алгоритм тестирования

Алгоритм функционального тестирования программного обеспечения на формальном языке можно представить следующим образом:

1. Начало тестирования.
2. Подготовить набор тестовых данных заемщика.
3. Выбрать способ ввода данных:
 - если используется ручной ввод, открыть формы приложения и заполнить поля заемщика;
 - если используется загрузка из файла, выбрать JSON-файл с данными заемщика.
4. Проверить корректность заполнения обязательных полей.
5. Если обязательные поля не заполнены или данные имеют некорректный формат, вывести сообщение об ошибке и перейти к шагу 13.
6. Сформировать входную JSON-структуру для Python-модуля предсказания.
7. Запустить Python-скрипт предсказания из C#-приложения.
8. Передать сформированный JSON-файл в модуль предсказания.
9. Получить выходной JSON с результатами скоринга.
10. Проверить наличие в выходных данных следующих полей:

- вероятность дефолта;
- скоринговый балл;
- уровень кредитного риска;
- решение о выдаче кредита;
- факторы, влияющие на решение модели.

11. Отобразить результат в пользовательском интерфейсе.
12. Сравнить фактический результат работы программы с ожидаемым результатом.
13. Зафиксировать результат тестирования.
14. Конец тестирования.

2.1.2 Классы эквивалентности

Для проверки корректности работы программного обеспечения были выделены классы эквивалентности входных данных. Это позволило сократить количество тестовых случаев и при этом проверить основные варианты поведения системы.

В качестве тестовых наборов использовались данные заемщиков с различными характеристиками: заемщик с низким уровнем риска, заемщик со средней кредитной нагрузкой, заемщик с высоким уровнем риска, пенсионер, а также заемщик с большим количеством просрочек и отказов. Такой набор тестов позволил проверить корректность заполнения всех полей формы, передачу данных в модуль предсказания и формирование итогового результата скоринга.

Таблица 1 – Классы эквивалентности входных данных

Класс данных	Описание класса	Ожидаемый результат
Корректные данные заемщика	Все обязательные поля заполнены, числовые значения находятся в допустимых пределах	Данные принимаются системой
Незаполненные обязательные поля	Отсутствует одно или несколько обязательных значений, необходимых для расчета скоринга	Пользователю выводится сообщение об ошибке
Некорректный формат данных	В числовые поля введены текстовые значения или данные имеют неверный формат	Данные не передаются в модель, выводится сообщение об ошибке
Корректный JSON-файл	JSON-файл имеет правильную структуру и содержит необходимые поля	Файл загружается, данные передаются в модуль предсказания
Некорректный JSON-файл	JSON-файл поврежден или не соответствует требуемой структуре	Пользователю выводится сообщение об ошибке
Заемщик с низким уровнем риска	Доход достаточен, кредитная нагрузка низкая, просрочки отсутствуют	Программа формирует результат скоринга без ошибок
Заемщик со средним уровнем риска	Присутствует умеренная кредитная нагрузка или отдельные факторы риска	Программа формирует результат скоринга без ошибок
Заемщик с высоким уровнем риска	Имеются просрочки, высокая кредитная нагрузка или большое количество отказов	Программа формирует результат скоринга без ошибок

2.1.3 Результаты функционального тестирования

Результаты проведенного функционального тестирования представлены в таблице 2.

Таблица 2 – Результаты функционального тестирования

Проверяемый сценарий	Ожидаемый результат	Результат
Ручной ввод данных заемщика	Данные принимаются системой и проходят проверку заполнения	Успешно
Формирование JSON по данным формы	Создается JSON-структура, соответствующая формату входных данных модели	Успешно
Загрузка данных из JSON-файла	Файл считывается, данные передаются в модуль предсказания	Успешно
Запуск Python-скрипта из C#	Python-модуль запускается из приложения и получает путь к входному файлу	Успешно
Получение результата скоринга	Приложение получает JSON с вероятностью дефолта, баллом и уровнем риска	Успешно
Отображение результата	На форме отображаются вероятность дефолта, скоринговый балл, уровень риска, факторы и рекомендации	Успешно
Обработка некорректных данных	Пользователю выводится сообщение об ошибке без аварийного завершения программы	Успешно

По результатам функционального тестирования установлено, что разработанное программное обеспечение корректно выполняет основные пользовательские сценарии. Приложение обеспечивает ручной ввод данных заемщика, загрузку данных из JSON-файла, формирование входной структуры данных, запуск Python-модуля предсказания, получение результата скоринга и отображение итоговой оценки пользователю.

При проверке некорректных входных данных программа не завершалась аварийно, а выводила сообщение об ошибке. Это подтверждает корректность обработки ошибочных ситуаций на уровне пользовательского сценария.

Функциональное тестирование подтвердило корректность работы основных компонентов программного комплекса.

2.2 Модульное тестирование

Модульное тестирование не проводилось.

2.3 Тестирование графического интерфейса

Тестирование графического интерфейса не проводилось.

Выводы

В ходе тестирования была проверена корректность работы программного обеспечения для оценки кредитоспособности физических лиц. Были протестированы основные функциональные сценарии: ручной ввод данных заемщика, загрузка данных из JSON-файла, формирование входной структуры данных, запуск Python-модуля предсказания, получение результата скоринга и отображение результата в пользовательском интерфейсе.

Результаты функционального тестирования показали, что разработанное программное обеспечение выполняет основные функции корректно. Приложение принимает данные заемщика, формирует JSON-структуру, передает данные в Python-модуль и получает результат скоринга без нарушения общего сценария работы.

Проверена обработка ошибочных ситуаций, связанных некорректными входными данными или отсутствием файла. В таких случаях пользователю выводится сообщение об ошибке, а программа не завершается аварийно.

Модульное тестирование и тестирование графического интерфейса в рамках практики не проводились.

3 Исследование разработанного ПО

В данном разделе проводится исследование характеристик разработанного программного обеспечения для оценки кредитоспособности физических лиц с использованием алгоритма градиентного бустинга деревьев решений.

В отличие от функционального тестирования, целью которого являлась проверка корректности выполнения основных сценариев работы приложения, в данном разделе рассматриваются качественные характеристики разработанного программного комплекса. Основное внимание уделяется способности модели выявлять заемщиков с высоким риском дефолта, влиянию порога классификации на результат скоринга и применимости разработанного программного обеспечения для предварительной оценки кредитного риска.

3.1 Постановка и условия исследования

Целью исследования является оценка характеристик разработанного программного обеспечения при решении задачи кредитного скоринга физических лиц.

Для достижения поставленной цели необходимо решить следующие задачи:

- определить зафиксированные и варьируемые факторы исследования;
- оценить качество классификации заемщиков на тестовой выборке;
- проанализировать влияние порога классификации на количество ошибок;
- исследовать способность модели разделять заемщиков по уровню кредитного риска;
- определить практическую применимость разработанного программного обеспечения.

Объектом исследования является разработанный программный комплекс оценки кредитоспособности физических лиц.

Предметом исследования являются характеристики программного комплекса, связанные с качеством классификации заемщиков и устойчивостью результатов скоринга при изменении порога классификации.

Разработанное программное обеспечение включает два основных компонента: пользовательский интерфейс, реализованный на языке C# с использованием Windows Forms, и модуль предсказания, реализованный на языке Python. Пользовательский интерфейс обеспечивает ввод данных и отображение результата, а Python-модуль выполняет обработку входных данных, загрузку обученной модели и расчет вероятности дефолта.

Исследование проводилось на тестовой выборке, которая не использовалась при обучении модели. Исходный набор данных был разделен на обучающую и тестовую выборки в соотношении 80% и 20%. Такое разделение позволило оценить способность модели работать с новыми данными.

В качестве исходных данных использовался открытый набор Home Credit Default Risk. Данный набор содержит сведения о заявках клиентов, кредитной истории, предыдущих заявках и платежной дисциплине заемщиков. Положительным классом в рассматриваемой задаче является наступление дефолта заемщика.

В рамках исследования были выделены зафиксированные и варьируемые факторы.

К зафиксированным факторам относятся:

- используемый набор данных;
- алгоритм машинного обучения LightGBM;
- состав входных признаков;
- структура входного JSON-файла;
- структура выходного JSON-файла;
- способ взаимодействия C#-приложения с Python-модулем;
- соотношение обучающей и тестовой выборок 80% и 20%.

К варьируемым факторам относятся:

- порог классификации;
- значения гиперпараметров модели;
- характеристики заемщика;
- уровень кредитной нагрузки;
- наличие или отсутствие просрочек;
- количество предыдущих отказов и активных кредитов.

3.2 Результаты исследования

Характеристики разработанного программного обеспечения оценивались по метрикам Accuracy, Precision, Recall, F1-score и ROC-AUC.

Метрика Accuracy показывает общую долю верно классифицированных объектов. Однако в задаче кредитного скоринга данная метрика не может рассматриваться как основная, поскольку для исходных данных характерен дисбаланс классов: количество надежных заемщиков значительно превышает количество заемщиков с дефолтом.

Поэтому основное внимание в исследовании уделялось метрикам ROC-AUC, Recall и F1-score. Метрика ROC-AUC позволяет оценить способность модели разделять заемщиков по уровню кредитного риска. Метрика Recall показывает долю выявленных дефолтных заемщиков среди всех фактически дефолтных заемщиков. Метрика F1-score отражает баланс между точностью и полнотой.

Результаты оценки итоговой модели представлены в таблице 3.

Таблица 3 – Метрики качества итоговой модели

Метрика	Значение
Accuracy	0.48
ROC-AUC	0.777
Precision	0.12
Recall	0.89
F1-score	0.22

Полученные результаты показывают, что модель обладает высокой полнотой выявления дефолтных заемщиков. Значение Recall составило 0.89, что свидетельствует о способности модели выявлять большую часть заемщиков с высоким риском дефолта.

Значение Precision составило 0.12. Это означает, что среди заемщиков, отнесенных моделью к группе риска, присутствует значительное количество ложноположительных решений. Данная особенность объясняется выбранным порогом классификации и спецификой задачи кредитного скоринга.

Для кредитной организации пропуск заемщика с высоким риском дефолта является более критичным, чем направление надежного заемщика на дополнительную проверку. Поэтому при настройке модели приоритет был отдан повышению полноты выявления дефолтных заемщиков.

Значение ROC-AUC составило 0.777. Это подтверждает, что модель выполняет ранжирование заемщиков по уровню кредитного риска лучше случайного классификатора.

Дополнительно была проанализирована матрица ошибок итоговой модели, представленная в таблице 4.

Таблица 4 – Матрица ошибок итоговой модели

	Предсказано 0	Предсказано 1
Фактически 0	24972	31566
Фактически 1	561	4404

Из матрицы ошибок видно, что модель правильно выявила 4404 заемщика с дефолтом. Количество пропущенных дефолтных заемщиков составило 561. При этом 31566 надежных заемщиков были ошибочно отнесены к группе риска.

Такой результат связан с выбранным порогом классификации, равным 0.3. Понижение порога повышает чувствительность модели к дефолтным заемщикам, но одновременно увеличивает число ложноположительных решений.

Для исследования влияния порога классификации были рассмотрены значения 0.30, 0.50 и 0.70. Результаты представлены в таблице 5.

Анализ показал, что увеличение порога классификации снижает количество ложноположительных решений, однако одновременно увеличивает число пропущенных дефолтных заемщиков. При пороге 0.30 количество пропущенных дефолтов составляет 561, при пороге 0.50 оно увеличивается до 1563, а при пороге 0.70 достигает 3112.

Таблица 5 – Зависимость количества ошибок от порога классификации

Порог классификации	FN	FP
0.30	561	31566
0.50	1563	15323
0.70	3112	4462

Следовательно, повышение порога делает модель более строгой при отнесении заемщика к группе риска, но ухудшает способность выявлять дефолтных заемщиков. В рамках данной работы был выбран порог 0.3, поскольку он позволяет уменьшить количество пропущенных заемщиков с высоким риском дефолта.

На рисунке 3.1 представлена ROC-кривая итоговой модели.




Рисунок 3.1 – ROC-кривая итоговой модели

ROC-кривая показывает зависимость доли верно выявленных положительных объектов от доли ложноположительных срабатываний при изменении порога классификации. В рассматриваемой задаче положительным классом является дефолт заемщика.

Расположение ROC-кривой выше диагонали случайного классификатора показывает, что модель обладает способностью разделять заемщиков по уровню кредитного риска. Значение ROC-AUC, равное 0.777, подтверждает, что модель выполняет ранжирование заемщиков лучше случайного классификатора.

На рисунке 3.2 представлена Precision-Recall кривая итоговой модели.




Рисунок 3.2 – Precision-Recall кривая итоговой модели

Precision-Recall кривая использовалась для оценки качества выявления положительного класса при наличии дисбаланса данных. В отличие от ROC-кривой, данный график позволяет более наглядно оценить работу модели именно для редкого класса, которым в рассматриваемой задаче является дефолт заемщика.

По результатам анализа Precision-Recall кривой можно сделать вывод, что модель обеспечивает высокую полноту выявления дефолтных заемщиков, однако при этом значение точности остается невысоким. Это связано с выбранным порогом классификации 0.3, при котором модель чаще относит заемщиков к группе риска.

Для рассматриваемой задачи кредитного скоринга такой результат является приемлемым. Для банка пропуск дефолтного заемщика может привести к финансовым потерям, тогда как ошибочное отнесение надежного заемщика к группе риска может быть компенсировано дополнительной проверкой заявки.

Таким образом, исследование показало, что выбранный порог классификации соответствует цели снижения кредитного риска за счет повышения полноты выявления потенциально проблемных заемщиков.

3.3 Выводы

В ходе исследования были рассмотрены характеристики разработанного программного обеспечения для оценки кредитоспособности физических лиц.

В отличие от функционального тестирования, где проверялась корректность выполнения отдельных сценариев работы приложения, в данном разделе была исследована способность программного комплекса решать основную прикладную задачу — выявлять заемщиков с высоким риском дефолта.

Были определены зафиксированные и варьируемые факторы исследования. К зафиксированным факторам были отнесены набор данных, алгоритм LightGBM, состав входных признаков, структура входных и выходных данных, а также способ взаимодействия приложения с Python-модулем. К варьируемым факторам относятся порог классификации, гиперпараметры модели и характеристики заемщиков.

По результатам исследования установлено, что итоговая модель обеспечивает высокую полноту выявления дефолтных заемщиков. Значение Recall составило 0.89, что свидетельствует о способности модели выявлять большую часть заемщиков с высоким риском дефолта.

Значение ROC-AUC, равное 0.777, показывает, что модель способна разделять заемщиков по уровню кредитного риска лучше случайного классификатора.

Анализ влияния порога классификации показал, что увеличение порога снижает количество ложноположительных решений, однако увеличивает число пропущенных дефолтов. Поэтому для итоговой модели был выбран порог 0.3, позволяющий уменьшить количество пропущенных заемщиков с высоким риском дефолта.

Таким образом, исследование подтвердило применимость разработанного программного обеспечения для предварительной оценки кредитного риска. Разработанное приложение может использоваться как вспомогательный инструмент поддержки принятия решений, при этом окончательное решение о выдаче кредита должно приниматься с учетом дополнительной проверки и экспертной оценки специалиста.

ЗАКЛЮЧЕНИЕ

В ходе прохождения практики было разработано программное обеспечение для оценки кредитоспособности физических лиц с использованием алгоритма градиентного бустинга деревьев решений. Разработанный программный комплекс включает пользовательский интерфейс, реализованный на языке C# с использованием технологии Windows Forms, и модуль предсказания, реализованный на языке Python.

В рамках работы была реализована возможность ручного ввода данных заемщика, загрузки данных из JSON-файла, формирования входной структуры данных, запуска Python-модуля предсказания, получения результата скоринга и отображения итоговой оценки пользователю. Результат работы программы включает вероятность дефолта, скоринговый балл, уровень кредитного риска, факторы риска и рекомендации.

В рамках работы была проведена проверка функциональных возможностей разработанного программного обеспечения. В процессе тестирования проверялись основные сценарии работы приложения: ввод сведений о заемщике через формы приложения, создание JSON-структуры, загрузка данных из файла, запуск Python-скрипта из приложения, получение результата скоринга, отображение результата пользователю, а также обработка некорректных входных данных. По результатам функционального тестирования установлено, что разработанное программное обеспечение корректно выполняет основные пользовательские сценарии и не завершается аварийно при возникновении ошибочных ситуаций.

Для проверки входных данных были выделены классы эквивалентности, включающие корректные данные заемщика, незаполненные обязательные поля, некорректный формат данных, корректный и некорректный JSON-файл, а также различные профили заемщиков с низким, средним и высоким уровнем риска. Использование таких классов позволило проверить основные варианты поведения системы без избыточного увеличения количества тестовых случаев.

Модульное тестирование в рамках практики не проводилось. Тестирование графического интерфейса также не проводилось.

Также было проведено исследование характеристик разработанного программного обеспечения. В рамках исследования оценивалась способность мо-

дели выявлять заемщиков с высоким риском дефолта, анализировалось влияние порога классификации на количество ошибок, а также рассматривалась применимость разработанного программного комплекса для предварительной оценки кредитного риска.

По результатам исследования итоговая модель показала высокую полноту выявления дефолтных заемщиков. Значение Recall составило 0.89, что свидетельствует о способности модели выявлять значительную часть заемщиков с высоким риском дефолта. Значение ROC-AUC составило 0.777. Это показывает, что модель ранжирует заемщиков по уровню кредитного риска лучше случайного классификатора.

В ходе анализа было выявлено, что выбранный порог классификации, равный 0.3, позволяет уменьшить количество пропущенных дефолтных заемщиков. При этом увеличение порога классификации снижает количество ложноположительных решений, но одновременно увеличивает число пропущенных дефолтов. Для задачи кредитного скоринга выбранный подход является обоснованным, поскольку пропуск заемщика с высоким риском дефолта может привести к финансовым потерям.

Таким образом, результаты тестирования подтвердили корректность работы основных компонентов разработанного программного обеспечения, а результаты исследования показали применимость выбранного подхода для предварительной оценки кредитного риска физических лиц.