



Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Оценка кредитоспособности физических лиц в банковских системах с использованием алгоритма градиентного бустинга деревьев решений

Студент: Фролов Евгений ИУ7-85Б

Научный руководитель: Новик Наталья Владимировна


Москва, 2026

Кредитный скоринг

Кредитный скоринг — метод оценки вероятности дефолта или просрочки платежа заемщиком.

Кредитоспособность — способность заемщика своевременно и в полном объеме выполнять обязательства по кредиту.

Дефолт — невыполнение заемщиком обязательств по кредиту, например невозврат кредита или возникновение просроченной задолженности.



Цель и задачи

Цель работы — разработать метод оценки кредитоспособности физических лиц в банковских системах с использованием алгоритма градиентного бустинга деревьев решений.

Задачи:

- провести анализ предметной области;
- рассмотреть существующие методы оценки кредитоспособности;
- разработать метод оценки кредитоспособности на основе GBDT;
- описать этапы предобработки данных, обучения модели и интерпретации результатов;
- разработать программное обеспечение и оценить качество разработанной модели..

Градиентный бустинг деревьев решений

Градиентный бустинг — ансамблевый метод машинного обучения, в котором итоговая модель строится как сумма последовательных базовых моделей.

$$F(x) = F_0(x) + \sum_{m=1}^M \gamma_m h_m(x)$$

где

$F(x)$ — итоговая модель;

$F_0(x)$ — начальное приближение модели;

M — количество базовых моделей;

m — номер базовой модели;

γ_m — коэффициент вклада m -й модели;

$h_m(x)$ — базовая модель на m -й итерации.

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x)$$


где

$F_m(x)$ — модель на текущей итерации;

$F_{m-1}(x)$ — модель, полученная на предыдущей итерации;

γ_m — коэффициент шага;

$h_m(x)$ — базовая модель, обученная на текущем шаге.



Каждое новое дерево обучается на ошибках предыдущей модели, что позволяет учитывать сложные нелинейные зависимости между признаками заемщика и вероятностью дефолта.

Сравнение методов машинного обучения для кредитного скоринга


Критерий	<i>Градиентный бустинг</i>	Логистическая регрессия	Линейный дискриминантный анализ	Опорных векторов
Тип модели	Нелинейная	Линейная	Линейная	Нелинейная
Сложные зависимости	Высокая	Ограничена	Ограничена	Высокая
Обработка больших данных	Высокая	Высокая	Средняя	Низкая
Требования к предобработке	Низкие	Высокие	Высокие	Высокие
Поддержка параллельных вычислений	Да	Ограничена	Ограничена	Ограничена

Требования к разрабатываемому методу

1. Принимать на вход данные о заемщике, включающие анкетные, финансовые характеристики и сведения о кредитной истории.
2. Выполнять предварительную обработку исходных данных и преобразование признаков.
3. Использовать алгоритм градиентного бустинга деревьев решений для оценки кредитоспособности.
4. Формировать результат в виде вероятности дефолта, скорингового балла и уровня кредитного риска.
5. Обеспечивать возможность интерпретации результатов работы модели.

Оценка кредитоспособности заемщика (1/2)

IDEF0 диаграмма



Оценка кредитоспособности заемщика (2/2)

IDEF0 диаграмма






Схема алгоритма разработанного метода



Входные данные и признаковое пространство

Входные данные включают совокупность данных физического лица, отражающих его финансовое состояние, социально-демографические особенности и кредитную историю.

Параметры заемщика описывается вектором признаков:

$$X = (X_1, X_2, \dots, X_d),$$

где

- X — вектор признаков заемщика;
- x_i — значение i -го признака;
- d — количество признаков.

Структура программного комплекса

Программный комплекс включает:


- пользовательский интерфейс на C# Windows Forms;
- модуль логики системы на C#;
- модуль машинного обучения на Python;
- модуль подготовки данных для обучения модели.

Обмен данными между компонентами выполняется в формате JSON.

Формула расчета скорингового балла

$$Score = (1 - P_{default}) \cdot 1000$$

$P_{default}$ — вероятность дефолта, рассчитанная моделью.



Интерфейс пользователя

 1. Данные заемщика

Возраст

29

Пол

Женский

Семейное положение

Не женат / не замужем

Образование

Высшее

Тип занятости

Работающий

Профессия

Специалист

Стаж работы, лет

4

Ежемесячный доход

100000

Количество детей

0

Количество членов семьи

1

Есть автомобиль

Нет

Возраст автомобиля

0

Есть недвижимость

Да

Тип жилья

Дом / квартира

Рейтинг региона

2

В главное меню

Далее

 2. Параметры кредита

Сумма кредита

550000

Ежемесячный платеж

30000

Стоимость товара

600000

Срок кредита, месяцев

36

День подачи заявки

Пятница

Час подачи заявки

14

Назад

Далее

 3. Кредитная история и поведение

Общее количество кредитов

5

Количество активных кредитов

2

Количество закрытых кредитов

3

Были ли просрочки

Нет

Максимальная просрочка, дней

0

Доля просроченных платежей, %

5%

Количество предыдущих заявок

4

Количество одобренных заявок

3

Количество отказанных заявок

1

Средняя сумма предыдущей заявки

300000

Средняя сумма предыдущего кредита

280000

Средний платеж по предыдущим заявкам

18000

Количество платежей

30

Количество просроченных платежей

2

Средний фактический платеж

18000

Средний плановый платеж

18000

Назад

Рассчитать

Результат работы программы

JSON, использованный в скоринге

```
{
  "client_id": 0,
  "target": 0,
  "application": {
    "AMT_INCOME_TOTAL": 100000.0,
    "AMT_CREDIT": 550000.0,
    "AMT_ANNUITY": 30000.0,
    "AMT_GOODS_PRICE": 600000.0,
    "CODE_GENDER": "F",
    "CNT_CHILDREN": 0,
    "NAME_FAMILY_STATUS": "Single / not married",
    "NAME_EDUCATION_TYPE": "Higher education",
    "NAME_INCOME_TYPE": "Working",
    "OCCUPATION_TYPE": "Core staff",
    "CNT_FAM_MEMBERS": 1,
    "FLAG_OWN_CAR": "N",
    "FLAG_OWN_REALTY": "Y",
    "OWN_CAR_AGE": 0.0,
    "NAME_HOUSING_TYPE": "House / apartment",
    "DAYS_BIRTH": -10585,
    "DAYS_EMPLOYED": -1460,
    "DAYS_REGISTRATION": -3648.0,
    "DAYS_ID_PUBLISH": -2120,
    "DAYS_LAST_PHONE_CHANGE": -1134.0,
    "REGION_POPULATION_RELATIVE": 0.018801,
    "REGION_RATING_CLIENT": 2,
    "REGION_RATING_CLIENT_W_CITY": 2,
    "EXT_SOURCE_1": 0.5,
    "EXT_SOURCE_2": 0.5,
    "EXT_SOURCE_3": 0.5,
    "OBS_30_CNT_SOCIAL_CIRCLE": 2.0,
    "DEF_30_CNT_SOCIAL_CIRCLE": 2.0,
    "OBS_60_CNT_SOCIAL_CIRCLE": 2.0,
    "DEF_60_CNT_SOCIAL_CIRCLE": 2.0,
    "AMT_REQ_CREDIT_BUREAU_DAY": 0.0,
    "AMT_REQ_CREDIT_BUREAU_WEEK": 0.0,
    "AMT_REQ_CREDIT_BUREAU_MON": 0.0,
    "AMT_REQ_CREDIT_BUREAU_QRT": 0.0,
    "AMT_REQ_CREDIT_BUREAU_YEAR": 1.0,
    "WEEKDAY_APPR_PROCESS_START": "FRI"
  }
}
```

Заккрыть

Результат оценки

Скоринговый балл

577


Вероятность дефолта

42,3 %

Уровень риска

Средний

Шкала риска



Основные факторы риска

Рекомендации:

- Требуется дополнительная проверка заемщика
- Высокая долговая нагрузка (кредит значительно превышает доход)
- Зафиксированы просрочки по кредитной истории
- Были отказы по предыдущим заявкам



На главную

Показать JSON

Тестирование программного комплекса

В ходе тестирования проверялись следующие сценарии:

- ручной ввод данных заемщика через формы приложения;
- формирование входного JSON-файла;
- загрузка данных из JSON-файла;
- запуск Python-модуля предсказания из C# приложения;
- получение результата скоринга в формате JSON;
- отображение вероятности дефолта, скорингового балла и уровня риска;
- обработка некорректных входных данных.



Результаты исследования модели

Для оценки качества модели исходный набор данных был разделен на обучающую, тестовую и валидационную в соотношении 80% , 10% и 10% соответственно.

Использовались библиотеки Scikit-Learn и LightGBM

Основные метрики качества итоговой модели:


- Accuracy = 0.48 (общая точность);
- ROC-AUC = 0.777 (качество разделения классов);
- Precision = 0.12 (точность выявления дефолтов);
- Recall = 0.89 (полнота выявления дефолтов);
- F1-score = 0.22 (баланс precision и Recall).

Итоговая модель обеспечивает высокую полноту выявления дефолтных заемщиков (Recall = 0.89) и обладает удовлетворяющей способностью разделять классы (ROC-AUC = 0.777).

Сравнение моделей машинного обучения

Для сравнительного исследования были выбраны следующие алгоритмы:

- логистическая регрессия;
- случайный лес;
- градиентный бустинг LightGBM.




Сравнение выполнялось по метрикам ROC-AUC и F1-score.

По результатам исследования модель LightGBM показала наилучшее качество:

- ROC-AUC = 0.78 (способность модели различать заемщиков с разным уровнем кредитного риска);
- F1-score = 0.22 (баланс между точностью и полнотой выявления дефолтных заемщиков).


Сравнение моделей по метрикам



Наилучший результат показала модель LightGBM: ROC-AUC = 0.777.

Значения для остальных моделей:

- логистическая регрессия — 0.755;
- случайный лес — 0.729.



LightGBM лучше подходит для выявления заемщиков с высоким риском дефолта.

Заключение

Решены следующие задачи:

- проведен анализ предметной области;
- рассмотрены существующие методы оценки кредитоспособности;
- разработан метод оценки кредитоспособности на основе GBDT;
- описаны этапы предобработки данных, обучения модели и интерпретации результатов;
- разработано программное обеспечение и оценено качество разработанной модели.

Поставленная цель достигнута. Все поставленные задачи решены.